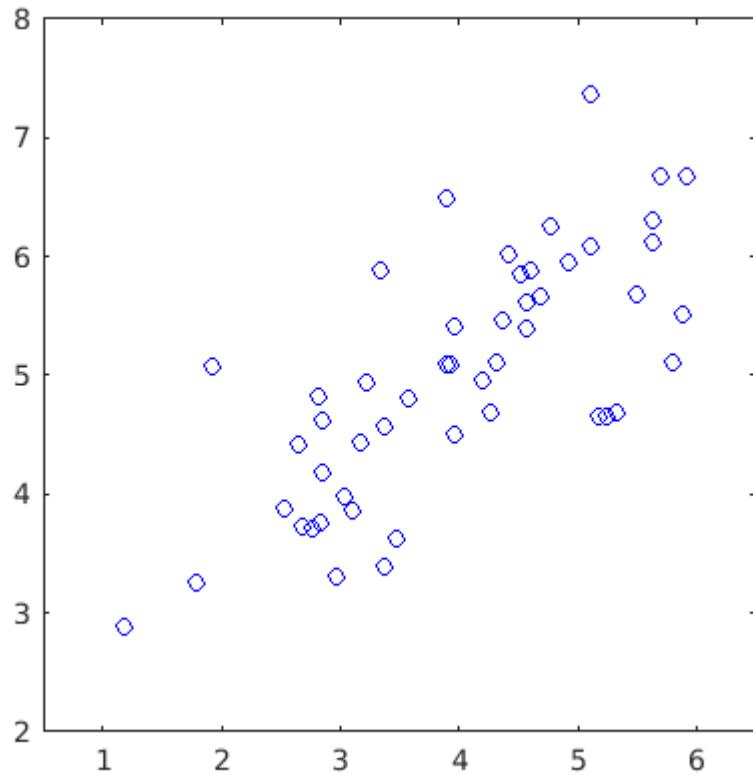


1. Загрузите данные **ex7data1.mat** из файла.

```
load('ex7data1.mat');
```

2. Постройте график загруженного набора данных.

```
figure;
plot(X(:, 1), X(:, 2), 'bo');
axis([0.5 6.5 2 8]); axis square;
```



3. Реализуйте функцию вычисления матрицы ковариации данных.

4. Вычислите координаты собственных векторов для набора данных с помощью сингулярного разложения матрицы ковариации (разрешается использовать библиотечные реализации матричных разложений).

```
function [U, S] = pca(X)
[m, n] = size(X);

U = zeros(n);
S = zeros(n);

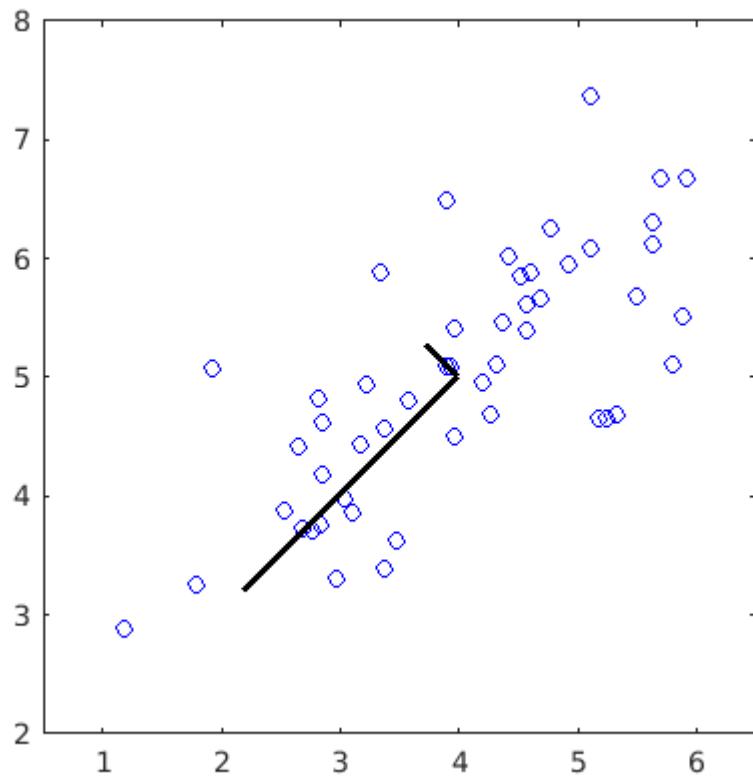
Sigma = 1.0/m .* X' * X;

[U, S, V] = svd(Sigma);
```

```
end
```

5. Постройте на графике из пункта 2 собственные векторы матрицы ковариации.

```
[X_norm, mu, ~] = featureNormalize(X);  
  
[U, S] = pca(X_norm);  
  
hold on;  
drawLine(mu, mu + 1.5 * S(1,1) * U(:,1)', '-k', 'LineWidth', 2);  
drawLine(mu, mu + 1.5 * S(2,2) * U(:,2)', '-k', 'LineWidth', 2);  
hold off;
```



```
fprintf('Top eigenvector U(:,1) = %f %f \n', U(1,1), U(2,1));
```

```
Top eigenvector U(:,1) = -0.707107 -0.707107
```

6. Реализуйте функцию проекции из пространства большей размерности в пространство меньшей размерности с помощью метода главных компонент.

```
function Z = projectData(X, U, K)  
  
Z = zeros(size(X, 1), K);
```

```

for i=1:size(X, 1),
for j=1:K,
x = X(i, :)';
projection_k = x' * U(:, j);
Z(i, j) = projection_k;
end
end

end

```

7. Реализуйте функцию вычисления обратного преобразования.

```

function X_rec = recoverData(Z, U, K)

X_rec = zeros(size(Z, 1), size(U, 1));

for i=1:size(Z, 1),
for j=1:size(U, 1),
v = Z(i, :)';
recovered_j = v' * U(j, 1:K)';
X_rec(i, j) = recovered_j;
end
end

end

```

8. Постройте график исходных точек и их проекций на пространство меньшей размерности (с линиями проекций).

```

% Project the data onto K = 1 dimension
K = 1;
Z = projectData(X_norm, U, K);
fprintf('Projection of the first example: %f\n', Z(1));

```

Projection of the first example: 1.481274

```

X_rec = recoverData(Z, U, K);
fprintf('Approximation of the first example: %f %f\n', X_rec(1, 1), X_rec(1, 2));

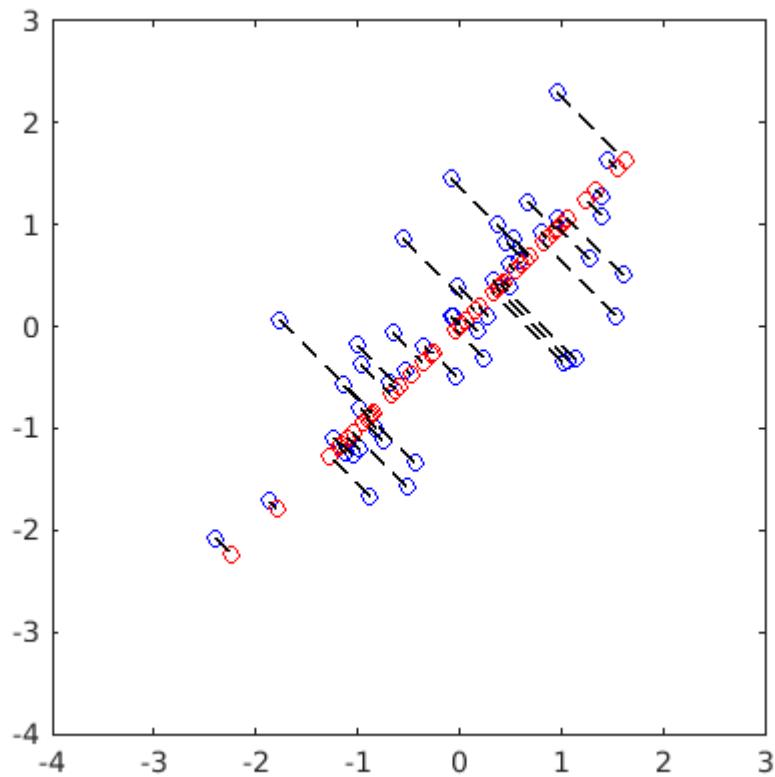
```

Approximation of the first example: -1.047419 -1.047419

```

plot(X_norm(:, 1), X_norm(:, 2), 'bo');
axis([-4 3 -4 3]); axis square
hold on;
plot(X_rec(:, 1), X_rec(:, 2), 'ro');
for i = 1:size(X_norm, 1)
    drawLine(X_norm(i,:), X_rec(i,:), '--k', 'LineWidth', 1);
end
hold off

```



9. Загрузите данные **ex7faces.mat** из файла.

10. Визуализируйте 100 случайных изображений из набора данных.

```
load ('ex7faces.mat')
displayData(X(1:100, :));
```



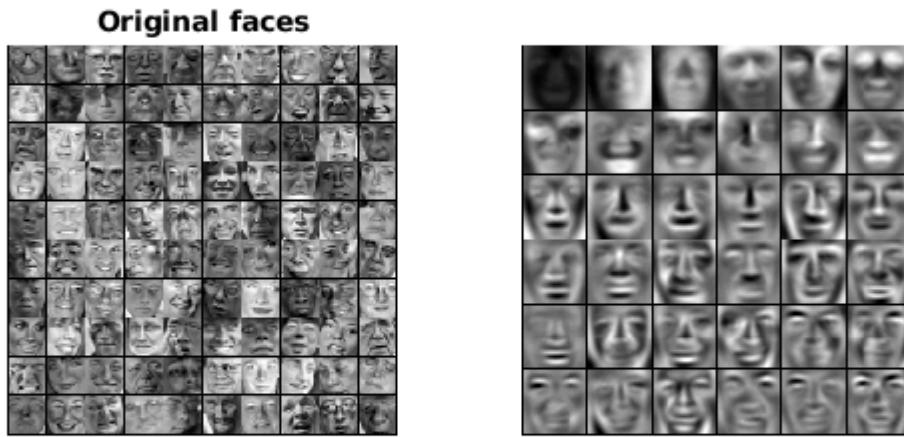
11. С помощью метода главных компонент вычислите собственные векторы.

12. Визуализируйте 36 главных компонент с наибольшей дисперсией.

```
[X_norm, ~, ~] = featureNormalize(X);  
[U, ~] = pca(X_norm)
```

```
U = 1024x1024  
-0.0143 -0.0361 -0.0456 0.0336 -0.0080 0.0470 -0.0289 0.0209 ...  
-0.0147 -0.0381 -0.0476 0.0334 -0.0071 0.0471 -0.0289 0.0212  
-0.0150 -0.0399 -0.0508 0.0333 -0.0048 0.0462 -0.0279 0.0222  
-0.0153 -0.0414 -0.0533 0.0317 -0.0016 0.0443 -0.0259 0.0236  
-0.0155 -0.0432 -0.0555 0.0296 0.0010 0.0417 -0.0222 0.0242  
-0.0156 -0.0449 -0.0574 0.0266 0.0046 0.0378 -0.0152 0.0239  
-0.0161 -0.0467 -0.0579 0.0222 0.0110 0.0332 -0.0092 0.0232  
-0.0164 -0.0479 -0.0577 0.0168 0.0179 0.0267 -0.0038 0.0214  
-0.0166 -0.0485 -0.0575 0.0117 0.0232 0.0207 0.0006 0.0215  
-0.0168 -0.0495 -0.0582 0.0076 0.0273 0.0137 -0.0013 0.0205  
:  
:
```

```
displayData(U(:, 1:36)');
```



14. Визуализируйте 100 главных компонент с наибольшей дисперсией.

```
K = 100;
Z = projectData(X_norm, U, K);

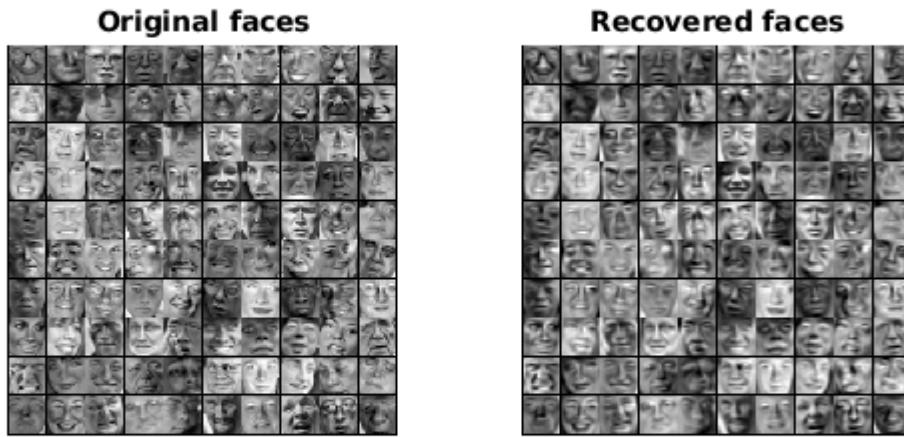
fprintf('The projected data Z has a size of: %d x %d', size(Z));
```

The projected data Z has a size of: 5000 x 100

```
X_rec = recoverData(Z, U, K);

subplot(1, 2, 1);
displayData(X_norm(1:100,:));
title('Original faces');
axis square;

subplot(1, 2, 2);
displayData(X_rec(1:100,:));
title('Recovered faces');
axis square;
```



15. Используйте изображение, сжатое в лабораторной работе №6 (Кластеризация).

16. С помощью метода главных компонент визуализируйте данное изображение в 3D и 2D.

```
clear;
% Re-load the image from the previous exercise and run K-Means on it
% For this to work, you need to complete the K-Means assignment first
A = double(imread('bird_small.png'));
A = A / 255;
img_size = size(A);
X = reshape(A, img_size(1) * img_size(2), 3);
K = 16;
max_iters = 10;
initial_centroids = kMeansInitCentroids(X, K);
[centroids, idx] = runkMeans(X, initial_centroids, max_iters);
```

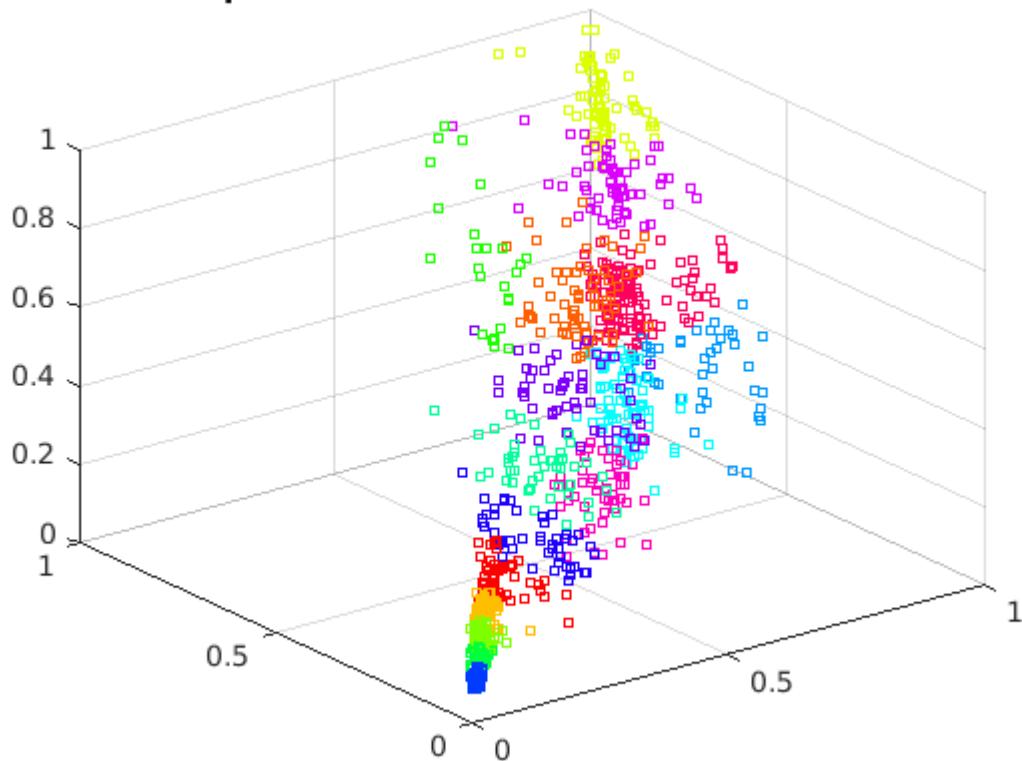
```
K-Means iteration 1/10...
K-Means iteration 2/10...
K-Means iteration 3/10...
K-Means iteration 4/10...
K-Means iteration 5/10...
K-Means iteration 6/10...
K-Means iteration 7/10...
K-Means iteration 8/10...
K-Means iteration 9/10...
K-Means iteration 10/10...
```

```
% Sample 1000 random indexes (since working with all the data is
% too expensive. If you have a fast computer, you may increase this.
sel = floor(rand(1000, 1) * size(X, 1)) + 1;

% Setup Color Palette
palette = hsv(K);
colors = palette(idx(sel), :);

% Visualize the data and centroid memberships in 3D
figure;
scatter3(X(sel, 1), X(sel, 2), X(sel, 3), 10, colors);
title('Pixel dataset plotted in 3D. Color shows centroid memberships');
```

Pixel dataset plotted in 3D. Color shows centroid memberships



```
% Subtract the mean to use PCA
[X_norm, mu, sigma] = featureNormalize(X);

% PCA and project the data to 2D
[U, S] = pca(X_norm);
Z = projectData(X_norm, U, 2);

% Plot in 2D
figure;
plotDataPoints(Z(sel, :), idx(sel), K);
title('Pixel dataset plotted in 2D, using PCA for dimensionality reduction');
```

Pixel dataset plotted in 2D, using PCA for dimensionality reduction

